重庆大学本科学生毕业论文（设计）

风电功率深度学习预测方法研究

学　　生：王锦源

学　　号：20221067

指导教师：赵霞

助理指导教师：XXX

专　　业：电气工程及其自动化

重庆大学电气工程及其自动化学院

2026 年 6 月

Undergraduate Thesis (Design) of Chongqing University

Research on Deep Learning Prediction Method for Wind Power

By

WANG Jin Yuan

Supervised by

Prof. ZHAO Xia

and

Prof. LI XX

Electrical Engineering and Automation

SCHOLL OF ELECTRICAL ENGINEERING

Chongqing University

June, 2026

摘 要

摘要是论文（设计）内容不加注释和评论的简短陈述，应具有独立性和自明性，即不阅读论文（设计）的全文，就可以获得必要的信息。

摘要一般应说明研究工作的目的和意义、研究思想和方法、研究过程、研究结果和最终结论等。摘要中一般不用图、表、化学结构式、计算机程序，不用非公知公用的符号、术语和非法定的计量单位。

中文摘要一般为 300 500 汉字。

摘要页置于英文题名页后。

关键词是从论文（设计）题名、摘要或正文中选取的对表示论文（设计）主题内容起关键作用，且具有检索意义的词或词组。一般每篇论文（设计）应选取 3 5 个词作为关键词，以显著的字符另起一行，排在同种语言摘要的下方，尽量用《汉语主题词表》或各专业主题词表提供的规范词。

关键词与摘要的内容之间空一行。关键词的词间用分号间隔，末尾不加标点。

关键词：关键词一；关键词二；关键词三

ABSTRACT

This is the English abstract. The abstract should be a concise summary of the thesis (design), providing an overview of the research purpose, methodology, process, results, and conclusions. It should be self-contained and independent, allowing readers to grasp the essential information without reading the full text.

Figures, tables, chemical structural formulas, computer programs, non-public symbols, terms, and non-statutory measurement units should generally not be used in the abstract.

The English abstract is typically 300-500 words and is placed after the English title page.

Keywords: Keyword One; Keyword Two; Keyword Three

目 录

摘要 I
ABSTRACT II
1 绪论 1
1.1 研究背景 1
1.1.1 风电功率预测的现实背景 1
1.1.2 深度学习用于风电功率预测的背景 1
1.2 国内外研究现状 2
1.2.1 国外研究现状 2
1.2.2 国内研究现状 3
1.2.3 现有研究评述 4
1.3 本文主要研究内容 4
1.4 本文结构安排 5
2 风电功率预测数据集与预处理 7
2.1 数据来源与数据集介绍 7
2.2 数据清洗 8
2.3 数据可视化和特征相关性分析 9
2.4 特征工程与归一化处理 11
2.5 滑动时间窗口构造 12
2.6 训练集、验证集和测试集划分 12
3 深度学习预测模型理论基础 13
3.1 卷积神经网络 CNN 原理 13
3.2 长短期记忆网络 LSTM 原理 15
3.3 门控循环单元 GRU 原理 16
3.3.1 重置门和更新门 17
3.3.2 候选隐状态 17
3.3.3 隐状态更新 18
3.4 CNN-LSTM 混合模型原理 19
3.5 模型评价指标 19
3.6 实验环境与超参数设置 19
4 单一深度学习模型的风电功率预测建模 20
4.1 CNN 预测模型构建 20
4.2 LSTM 预测模型构建 20

4.3 GRU 预测模型构建 20
4.4 三种单模型训练流程设计 20
4.5 单模型初步实验结果分析 20
5 基于 CNN-LSTM 的混合模型构建与优化 21
5.1 构建 CNN-LSTM 混合模型的必要性分析 21
5.2 CNN-LSTM 网络结构设计 21
5.3 模型训练过程与参数优化 21
5.4 CNN-LSTM 模型预测流程 21
5.5 混合模型相较于单模型的理论优势分析 21
6 实验结果分析与模型对比 22
6.1 实验方案设计 22
6.2 不同模型在同一风场上的预测结果对比 22
6.3 同一模型在不同风场上的泛化性能分析 22
6.4 预测结果可视化分析 22
6.5 基于 MAPE、MAE、RMSE 的综合评价 22
6.6 模型优缺点与误差来源分析 22
6.7 最优模型选择与适用场景讨论 22
7 结论与展望 23
7.1 研究工作总结 23
7.2 主要结论 23
7.3 不足与展望 23

1 绪论

1.1 研究背景

1.1.1 风电功率预测的现实背景

在全球能源结构加速向低碳、清洁转型的背景下，风力发电作为最具发展潜力的可再生能源之一，已经在现代电力系统中占据重要地位[1-2]。相比于传统火电，风电具有资源储量大、分布广泛、清洁无污染以及可持续利用等优势[3]。近年来，随着风电装机容量不断增长，电力系统中风电渗透率持续提高，但风电具有明显的随机性、波动性、间歇性和不确定性，其输出功率难以像传统火电机组一样实现精准调节，进而对电网调峰、调频以及经济调度带来更大挑战[4,3]。

为了给电网调度提供可靠的决策依据，减少备用容量配置，缓解系统调峰压力，提高电网对风电的消纳能力，风电功率预测已经成为风电并网运行中的关键环节[5,1]。准确的风电功率预测不仅能够为电网调度提供有力支持，降低系统运行成本，还能够提高电网运行的安全性、经济性与可靠性[6,2]。

1.1.2 深度学习用于风电功率预测的背景

随着新能源高比例接入电力系统，风电短期预测和超短期预测的重要性不断提高，其应用范围也已经由传统调度逐步扩展到功率控制、风险评估、概率预测以及集群协同优化等多个方面[5,2]。

从方法演进来看，风电预测研究已经从早期的持续法、物理方法和统计方法，逐步发展到浅层机器学习方法和深度学习方法[1,4]。传统方法在一定场景下具有实现简单或机理明确等优点，但在面对风电数据强非线性、多变量耦合、时序依赖显著以及不确定性强等特点时，往往难以兼顾预测精度与模型泛化能力[7-8]。

从预测时间尺度来看，风电功率预测主要包括超短期预测、短期预测和中长期预测。其中，超短期预测通常指 15 分钟到 6 小时的预测，主要用于电网调度和功率控制；短期预测通常指 6 小时到 24 小时的预测，主要用于电网调度和功率控制；中长期预测通常指 24 小时到 7 天的预测，主要用于电网调度和功率控制[5,2]。

表 1.1 风电功率预测时间尺度

预测时间尺度	预测时间	应用场景
超短期预测	15 分钟到 6 小时	电网调度和功率控制
短期预测	6 小时到 24 小时	电网调度和功率控制
中长期预测	24 小时到 7 天	电网调度和功率控制

近年来，随着数据采集能力、计算能力和人工智能技术的快速发展，深度学习方法在风电功率预测中的应用越来越广泛[8,1]。综述研究表明，卷积神经网络（CNN）、长短期记忆网络（LSTM）、门控循环单元（GRU）等模型在处理风电数

据的非线性和复杂性方面具有明显优势[8,4]。其中，CNN 擅长提取局部特征以及多变量之间的潜在关联，LSTM 和 GRU 在捕捉时间序列依赖关系和长期特征方面表现突出，而混合模型如 CNN-LSTM 则能够同时兼顾特征提取和时序建模，更适合处理风电功率这种兼具复杂波动性和时间相关性的时序数据[9-10]。

此外，多模型融合、图神经网络以及 Transformer 等新型方法在风电功率预测中也展现出良好的应用潜力[11,4]。基于此，围绕典型深度学习模型开展风电功率预测研究，不仅有助于提升预测精度和模型鲁棒性，也能够为新能源高比例接入背景下的风电场运行优化和电网调度提供理论依据与技术支持[1,8]。

1.2 国内外研究现状

1.2.1 国外研究现状

风电功率预测研究起步较早，国外已逐步形成较为系统的理论体系与应用框架。早期研究主要围绕物理方法、统计方法以及传统机器学习方法展开，其中物理方法通常结合数值天气预报（Numerical Weather Prediction，NWP）与风机功率曲线进行建模，能够反映气象条件与风电功率之间的机理联系；统计方法则主要利用历史时间序列建立输入与输出之间的映射关系，具有建模相对简便的特点[3,2]。然而，随着风电并网规模不断扩大，风电数据所呈现出的非平稳性、随机性、波动性和时序相关性日益突出，传统方法在复杂场景下往往难以兼顾预测精度与泛化能力[7,1]。

随着人工智能和数据驱动技术的发展，机器学习方法逐渐成为国外风电功率预测研究的重要方向。支持向量机、随机森林、神经网络等方法在短期和超短期预测中得到了广泛应用，并在一定程度上提高了预测精度[1-2]。但已有研究表明，浅层模型在处理风电功率序列中的高维非线性关系、长期时间依赖以及复杂特征耦合方面仍存在一定局限，因此深度学习方法逐渐成为新的研究热点[7,1]。

近年来，卷积神经网络（CNN）、长短期记忆网络（LSTM）和门控循环单元（GRU）等深度学习模型被广泛应用于风电功率预测任务。其中，LSTM 能够有效捕捉时间序列中的长期依赖关系，较好地克服传统循环神经网络在训练过程中出现的梯度消失问题；CNN 则在局部特征提取和多变量关联建模方面具有优势；GRU 在保持较强时序建模能力的同时，具有结构相对简洁、训练效率较高等特点[12-13]。例如，Zhang 等构建了基于 LSTM 和高斯混合模型的短期风电功率预测与不确定性分析框架，验证了 LSTM 在提升预测精度方面的优势[13]；Yuan 等进一步将 LSTM 与 Beta 分布和粒子群优化相结合，用于风电功率区间预测，提高了区间预测的可靠性与实用性[14]。

在单一深度学习模型的基础上，混合模型研究也不断增多。通过将 CNN 与

LSTM 结合，可以同时实现特征提取与时序建模，从而更好地适应风电功率序列兼具复杂波动性和时间相关性的特点[15,9]。此外，数据分解、参数优化、误差修正等辅助策略也被广泛引入模型构建过程中，以削弱原始序列中的噪声和非平稳性，提高预测模型的鲁棒性与泛化能力[7,15]。随着研究的进一步深入，图神经网络、Transformer、多模型融合以及概率预测方法也逐步成为国外研究的新方向。例如，He 等提出将爬坡特征识别、图卷积网络与误差修正机制相结合，用于提升风电功率剧烈波动场景下的预测性能，体现了风电预测研究向复杂场景建模和智能融合方向发展的趋势[11]。

1.2.2 国内研究现状

国内风电功率预测研究主要围绕新能源高比例并网、电网安全运行以及调度优化需求展开，已经形成了从理论研究到工程应用不断推进的发展态势。较早期研究重点集中在风电功率预测的分类、技术路线、误差评价与应用场景等方面。黎静华等对点预测、区间预测、概率预测和场景预测等进行了较为系统的归纳与梳理，指出风电功率预测在提高电网调度水平、促进风电消纳和支撑预测系统开发等方面具有重要作用[3]。徐曼等则从纵向误差、横向误差和极端误差等角度出发，提出了较为系统的短期风电功率预测误差综合评价方法，为模型性能分析和预测结果应用提供了参考[6]。

在方法研究方面，国内学者对物理方法、时间序列方法、人工智能方法及组合预测方法都开展了大量研究。韩自奋等总结了物理方法、时间序列方法、人工智能方法和组合方法的发展情况，并指出空间相关性预测、集群预测、不确定性预测和爬坡预测已成为风电预测的重要发展方向[2]。孙荣富等则从数值天气预报、风功率转换模型、预测结果应用和性能评价等全流程角度，对风电功率预测关键技术及应用进行了阶段性总结，反映出我国风电预测研究具有较强的工程导向和应用导向特征。

随着深度学习技术的发展，国内关于 LSTM、GRU 及其改进模型在风电功率预测中的应用研究持续增多。朱乔木等较早将 LSTM 引入风电场发电功率超短期预测，采用多变量时间序列进行动态建模，结果表明其预测效果优于传统人工神经网络和支持向量机方法[12]。李大中等提出基于 BiGRU 点预测、随机森林误差修正以及核密度估计区间分析的超短期风电功率预测方法，在提升预测精度的同时，进一步增强了模型在区间预测层面的实用价值[10]。可以看出，国内研究已逐步从单纯关注点预测精度，拓展到误差修正、概率分布拟合和区间预测等更贴近工程应用的研究方向。

此外，针对风电功率数据噪声强、波动大和非平稳特征明显的问题，国内外均广泛采用数据预处理与深度网络相结合的建模思路，如分解—预测—重构框架、

特征筛选、异常值剔除和归一化处理等[7,15]。这些研究表明，合理的数据处理策略有助于降低模型训练难度，提高预测精度和稳定性。在此基础上，国内研究也逐步关注深度学习模型的组合优化、误差反馈修正、多时间尺度建模以及新型网络结构的应用，整体呈现出从传统单模型向多模型融合和智能增强方向发展的趋势[10-11]。

1.2.3 现有研究评述

综上所述，国内外风电功率预测研究已经由早期的物理方法和统计方法，逐步发展到以机器学习和深度学习为核心的数据驱动建模阶段，并进一步向组合预测、概率预测、区间预测、爬坡事件预测和智能融合方向演进[3,2,1]。现有研究表明，LSTM、GRU、CNN 及其混合模型在风电功率预测中具有较强的适应性，能够较好地应对风电功率序列的非线性、波动性和时间相关性问题[12-13,15,9]。

但同时也应看到，当前研究仍存在一些不足。其一，单一模型在不同风场、不同气象条件和不同预测尺度下的泛化能力仍有限；其二，风电功率序列受噪声、异常值和数据缺失等因素影响明显，模型性能对数据质量较为敏感；其三，相比点预测，区间预测、概率预测和极端波动事件预测等更具工程价值的研究仍有进一步拓展空间；其四，部分先进模型结构较为复杂、参数较多，虽然预测性能较优，但在实际部署和工程实现中仍面临一定成本与难度[6-7,14,11]。

1.3 本文主要研究内容

针对风电功率序列随机性强、波动性明显、非线性特征突出以及传统预测方法在复杂场景下预测精度受限等问题，本文围绕深度学习模型在风电功率短期预测中的应用展开研究，结合风电场历史运行数据与相关气象特征，构建多模型对比分析框架，对典型深度学习模型在风电功率预测任务中的性能进行研究与比较。本文的主要研究内容如下：

（1）对风电功率预测的研究背景、应用价值及国内外研究现状进行系统梳理。结合风电并网规模不断扩大以及新能源高比例接入电力系统的发展背景，分析风电功率预测在电网调度、功率控制、运行优化和风电消纳中的重要作用，综述风电功率预测方法从物理方法、统计方法到机器学习方法、深度学习方法的发展历程，总结当前研究的主要进展、热点方向及存在问题[3,2,1,4]。

（2）完成风电功率预测数据集的预处理与样本构建。针对原始风电数据中可能存在的缺失值、异常值、量纲不一致及时间序列波动明显等问题，对数据集进行清洗、异常处理、特征分析与归一化处理，并采用滑动时间窗口方法将原始时间序列构造为适用于深度学习的输入输出样本，并完成训练集、验证集和测试集的划分，为后续模型训练与实验分析提供可靠的数据基础。

（3）研究典型深度学习模型的基本原理及其在风电功率预测中的适用性。围绕卷积神经网络（CNN）、长短期记忆网络（LSTM）、门控循环单元（GRU）以及 CNN-LSTM 混合模型，分析各类模型在局部特征提取、时序依赖建模、多变量耦合分析等方面的特点，结合风电功率序列兼具复杂波动性与时间相关性的特征，明确不同模型在预测任务中的理论优势与局限性。

（4）构建并实现 CNN、LSTM 和 GRU 三种单一深度学习预测模型。基于统一的数据输入方式和实验条件，分别设计 CNN、LSTM 和 GRU 风电功率预测模型，完成网络结构搭建、参数设置、模型训练及预测流程设计，对不同单一模型在风电功率预测任务中的表现进行初步分析，为后续混合模型构建与综合对比奠定基础。

（5）构建基于 CNN-LSTM 的混合预测模型，并对其结构与参数进行优化。针对单一模型在局部特征提取能力或长期时序依赖建模能力方面的局限，设计 CNN-LSTM 混合模型，将卷积层的特征提取能力与 LSTM 的时序建模能力相结合，完成网络结构设计、训练流程构建与关键参数优化，并从理论上分析混合模型相较于单一模型的优势。

（6）开展多模型对比实验与结果分析。基于统一的数据集和评价指标，分别对 CNN、LSTM、GRU 和 CNN-LSTM 四种模型开展风电功率预测实验，通过真实值与预测值曲线、误差变化曲线以及评价指标统计表，对不同模型在预测精度、波动跟踪能力、模型稳定性及泛化性能等方面进行综合对比分析，并进一步讨论误差来源及模型适用场景。

（7）总结全文研究工作，并对后续研究方向进行展望。在实验分析基础上，总结不同深度学习模型在风电功率预测中的性能特点，归纳本文的主要研究结论，并结合当前风电预测研究的发展趋势，对模型融合、误差修正、多步预测、概率预测以及引入注意力机制和 Transformer 等进一步研究方向进行展望。

1.4 本文结构安排

本文共分为七章，各章内容安排如下：

第 1 章为绪论。主要介绍风电功率预测的研究背景与现实意义，阐述深度学习应用于风电功率预测的研究基础，综述国内外相关研究现状，分析当前研究中存在的主要问题，并说明本文的主要研究内容与整体结构安排。

第 2 章为风电功率预测数据集与预处理。主要介绍实验所用风电功率数据集的来源、组成及基本特征，分析风速、风向、温度、气压、湿度等特征变量与功率之间的关系，并对原始数据进行缺失值处理、异常值处理、归一化处理和滑动时间窗口样本构造，最终完成训练集、验证集和测试集的划分，为模型训练与测试提供数据支撑。

第 3 章为深度学习预测模型理论基础。主要介绍 CNN、LSTM、GRU 以及

CNN-LSTM 混合模型的基本原理、网络结构及其在时间序列预测中的适用特点，同时给出本文采用的模型评价指标、实验环境及主要超参数设置，为后续模型构建与实验分析提供理论依据。

第 4 章为单一深度学习模型的风电功率预测建模。主要在统一实验条件下分别构建 CNN、LSTM 和 GRU 三种单一预测模型，介绍各模型的网络结构、输入输出形式、参数设置和训练流程，并结合初步实验结果分析不同单模型在风电功率预测任务中的表现特点。

第 5 章为基于 CNN-LSTM 的混合模型构建与优化。针对单一模型在风电功率预测中的局限性，分析构建 CNN-LSTM 混合模型的必要性，设计模型整体结构与预测流程，并对模型训练过程中的关键参数进行优化，在理论层面阐述混合模型在特征提取与时序建模协同方面的优势。

第 6 章为实验结果分析与模型对比。主要基于多个实验结果对 CNN、LSTM、GRU 和 CNN-LSTM 四种模型进行系统对比，通过预测曲线、误差曲线、散点图和评价指标表格等形式，从预测精度、鲁棒性、泛化能力和适用场景等角度展开分析，并总结不同模型的优缺点及误差来源。

第 7 章为结论与展望。主要对全文研究工作进行总结，概括本文在风电功率预测模型构建、实验分析与模型比较方面得到的主要结论，并结合深度学习在风电功率预测中的发展趋势，对后续研究方向进行展望。

2 风电功率预测数据集与预处理

2.1 数据来源与数据集介绍

本研究采用的风电场数据来源于公开数据集 Renewable-energy-generation-input-feature-variables-analysis，可通过 https://github.com/Bob05757/Renewable-energy-generation-input-feature-variables-analysis 获取。该数据集来自国家电网 2021 年举办的新能源发电预测竞赛，关于该数据集的数据说明可以从 SCIENCE 上的数据论文获取。

该数据集中风电数据来自中国六个风电场，数据由 SCADA 系统采集，时间分辨率为 15 分钟，从 2019-2020 年两年。每个风电场数据文件均记录了功率和气象变量，包括不同高度的风速，温度，湿度，气压、风向等共 11 项特征数据以及总功率输出，该数据论文指出轮毂高度风速是最重要变量之一。风电场分布在中国国北部，中部和西北部地形位置包括沙漠、山地、和平原。

各风电场数据集的结构基本一致，都包含采样时间以及 12 个气象和运行特征，其中时间字段为 `Time(year-month-day h:m:s)`，用于表征样本采集时刻；气象特征主要包括 10 m、30 m 和 50 m 高度处的风速与风向，轮毂高度处的风速与风向，以及空气温度、气压和相对湿度等变量。具体而言，输入特征字段共 12 个，分别为：Wind speed at height of 10 meters (m/s)、Wind direction at height of 10 meters (°)、Wind speed at height of 30 meters (m/s)、Wind direction at height of 30 meters (°)、Wind speed at height of 50 meters (m/s)、Wind direction at height of 50 meters (°)、Wind speed at the height of wheel hub (m/s)、Wind speed at the height of wheel hub (°)、Air temperature (°C)、Atmosphere (hpa)、Relative humidity (%)，以及时间信息所隐含的时序变化特征。目标变量为 Power (MW)，表示对应时刻风电场的实际输出功率。表 2.1 描述了各个列标题的含义和缩写，后续可视化为了方便将采取缩写形式。

表 2.1 风电场数据文件特征列名含义与缩写

Heading name	**Shortened name**	**Description**
Wind speed at height of x meters (m/s)	WS_x	记录距离地面 x 米处的风速
Wind direction at height of x meters (°)	WD_x	记录距离地面 x 米处的风向
Air temperature (°C)	Air_T	距离地面 1.5 米处的空气干球温度
Atmosphere (hpa)	Air_P	距离地面 1.5 米处的大气压
Relative humidity (%)	Air_H	距离地面 1.5 米处的空气相对湿度
Power output (MW)	–	风电场总发电功率

风电场部分统计信息如表 2.2 所示，风电装机容量范围为 36 MW 至 200 MW，实际平均出力介于 6.7 MW 至 72.7 MW 之间。轮毂高度处的风速变化区间为 0 m/s

至 36.9 m/s，年平均风速约为 6.0 m/s。气温变化范围为 −24.5 °C 至 37.6 °C，年平均气温为 8.5 °C。不同海拔高度的气象数据呈现相似变化趋势。总体而言，风速具有季节性特征，夏季风速较高，冬季风速较低。

表 2.2 风电场统计参数：各变量的均值、最小值、最大值及标准差

风电场	统计量	输出功率 (MW)	轮毂高度风速 (m/s)	轮毂高度风向 (°)	距地面 1.5 m 气温 (°C)	距地面 1.5 m 相对湿度 (%)
风电场 1	均值	23.4	6.4	217.0	8.5	37.6
	最小值	0.0	0.0	0.0	−24.1	0.0
	最大值	98.1	30.2	358.5	36.1	93.1
	标准差	24.1	3.9	85.4	13.4	18.9
风电场 2	均值	72.7	7.5	206.8	8.7	33.4
	最小值	0.0	0.0	0.0	−24.5	0.0
	最大值	201.2	28.8	359.8	37.6	97.6
	标准差	55.7	5.7	87.0	13.2	7.1
风电场 3	均值	18.1	4.0	179.1	17.4	58.5
	最小值	0.0	0.0	0.0	−14.3	0.0
	最大值	94.3	36.9	360.0	36.3	94.3
	标准差	22.6	3.3	110.5	9.9	23.8
风电场 4	均值	17.4	5.5	147.3	13.8	80.7
	最小值	0.0	0.0	0.0	−3.8	0.0
	最大值	64.6	31.1	356.8	35.3	100.0
	标准差	20.0	3.9	120.7	8.2	18.8
风电场 5	均值	6.7	4.7	184.9	13.6	69.9
	最小值	0.0	0.0	0.0	−9.9	0.0
	最大值	35.4	26.2	358.6	35.8	100.0
	标准差	10.1	3.1	113.2	8.9	32.2
风电场 6	均值	28.8	8.1	94.0	21.2	78.6
	最小值	0.0	0.0	0.0	0.0	0.0
	最大值	114.4	23.8	360.0	37.1	99.4
	标准差	28.0	3.8	91.2	6.4	10.9

2.2 数据清洗

本节主要对数据进行清洗，主要包括缺失值处理、异常值处理。

首先统计数据中的缺失值。本研究的缺失值包含零值、’NA’、’0.001’、’-99’和’–’。具体统计结果如表 2.3 所示。可以看到，所有六个风电场的样本总数均为 70176 条，各风电场的缺失值与异常值占比在 0.27% 至 5.13% 之间，处于较低水平。

针对数据处理逻辑：对于小步长（少于 10 步）缺失的数据样本，采用向上/向下补全的方法；当间断时间步（少于 100 步）缺失时，考虑移动平均法；对于长期（超过 100 步）数据缺失的情况，剔除这些样本。此外，如果缺失数据率大于总体的特定比例（即 20%），则不采用该风电场的数据集。

表 2.3 风电场数据集缺失值与异常值统计

风电场数据文件		
风电场	总样本量	缺失值与异常值比例
风电场 1	70176	1.58%
风电场 2		0.45%
风电场 3		1.39%
风电场 4		3.25%
风电场 5		5.13%
风电场 6		0.27%

2.3 数据可视化和特征相关性分析

输入特征的选择对提高预测精读至关重要，而相关性分析对于变量的选取具有重要意义。本文采用皮尔逊相关系数（The Pearson correlation coefficient,PCC）来分析各输入特征与输出变量之间的相关性，并结合热力图进行可视化分析。热力图如图2.1所示。

在功率方面，WS_x(即, 不同高度的风速) 具有最高的 PCC。轮毂高度对于风力机的每个模型来说是不同的，因此 WS_cen 代表了不同的高度。风电场场址 1、2、3、4、5、6 的轮毂高度分别为 85m、120m、80m、85m / 90m、90m、65m。因此风速对风电功率起主导作用，结合图2.2可以看出，实际风功率曲线呈现出典型的“S 型”非线性特征：当风速低于切入风速或高于切出风速时，功率基本为零；在切入与额定风速之间，功率随风速增加呈近似三次方增长；达到额定风速后，功率维持在额定值附近波动。

风向和功率呈现弱相关性，只在 1 风电场有 0.3-0.4 的 PCC，其他风电场 PCC 都很低。

温度、气压和湿度的 Pearson 相关系数在数值上表现为弱相关或极弱相关。然而，结合空气动力学原理 $\rho = \frac{P}{R_s T_v}$ 可知，这三个物理量共同决定了空气密度。在相同的风速下，温度越低、气压越高、湿度越小，空气密度越大，风轮扫掠面积内蕴含的动能就越高。因此，温压湿主要是通过改变空气密度对风电功率产生非线性的微扰，这也是图2.2风速-功率散点图中主曲线上存在一定宽度（离散性）的重要原因之一。

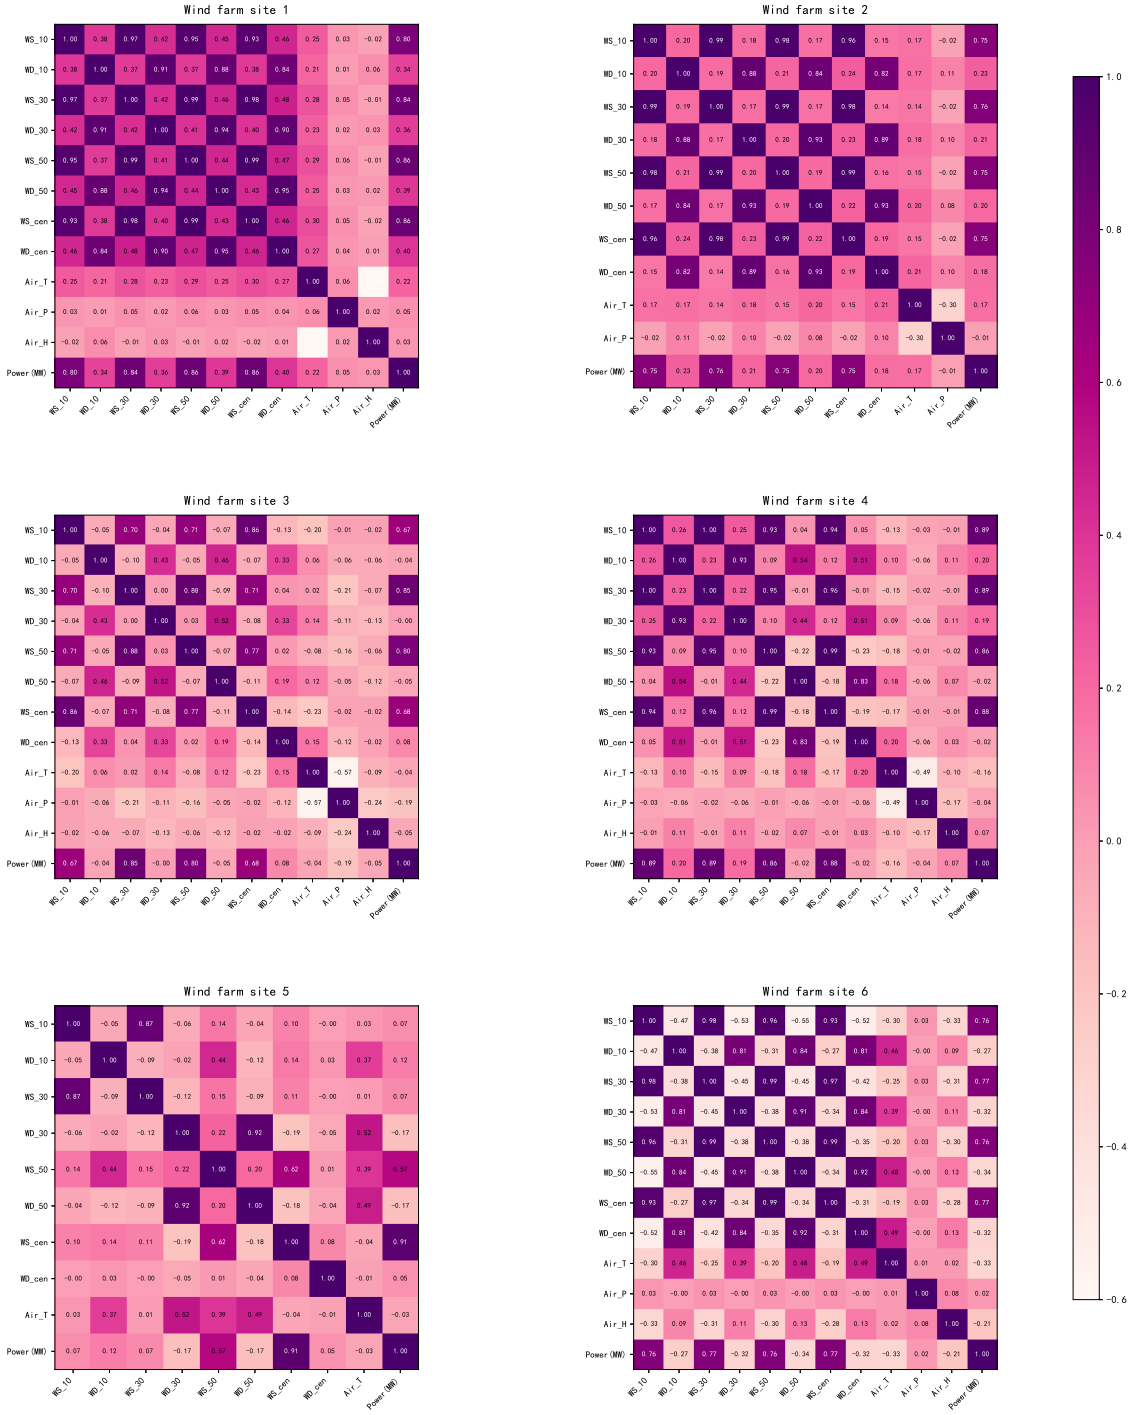

图 2.1 风电场不同变量的 Pearson 相关系数

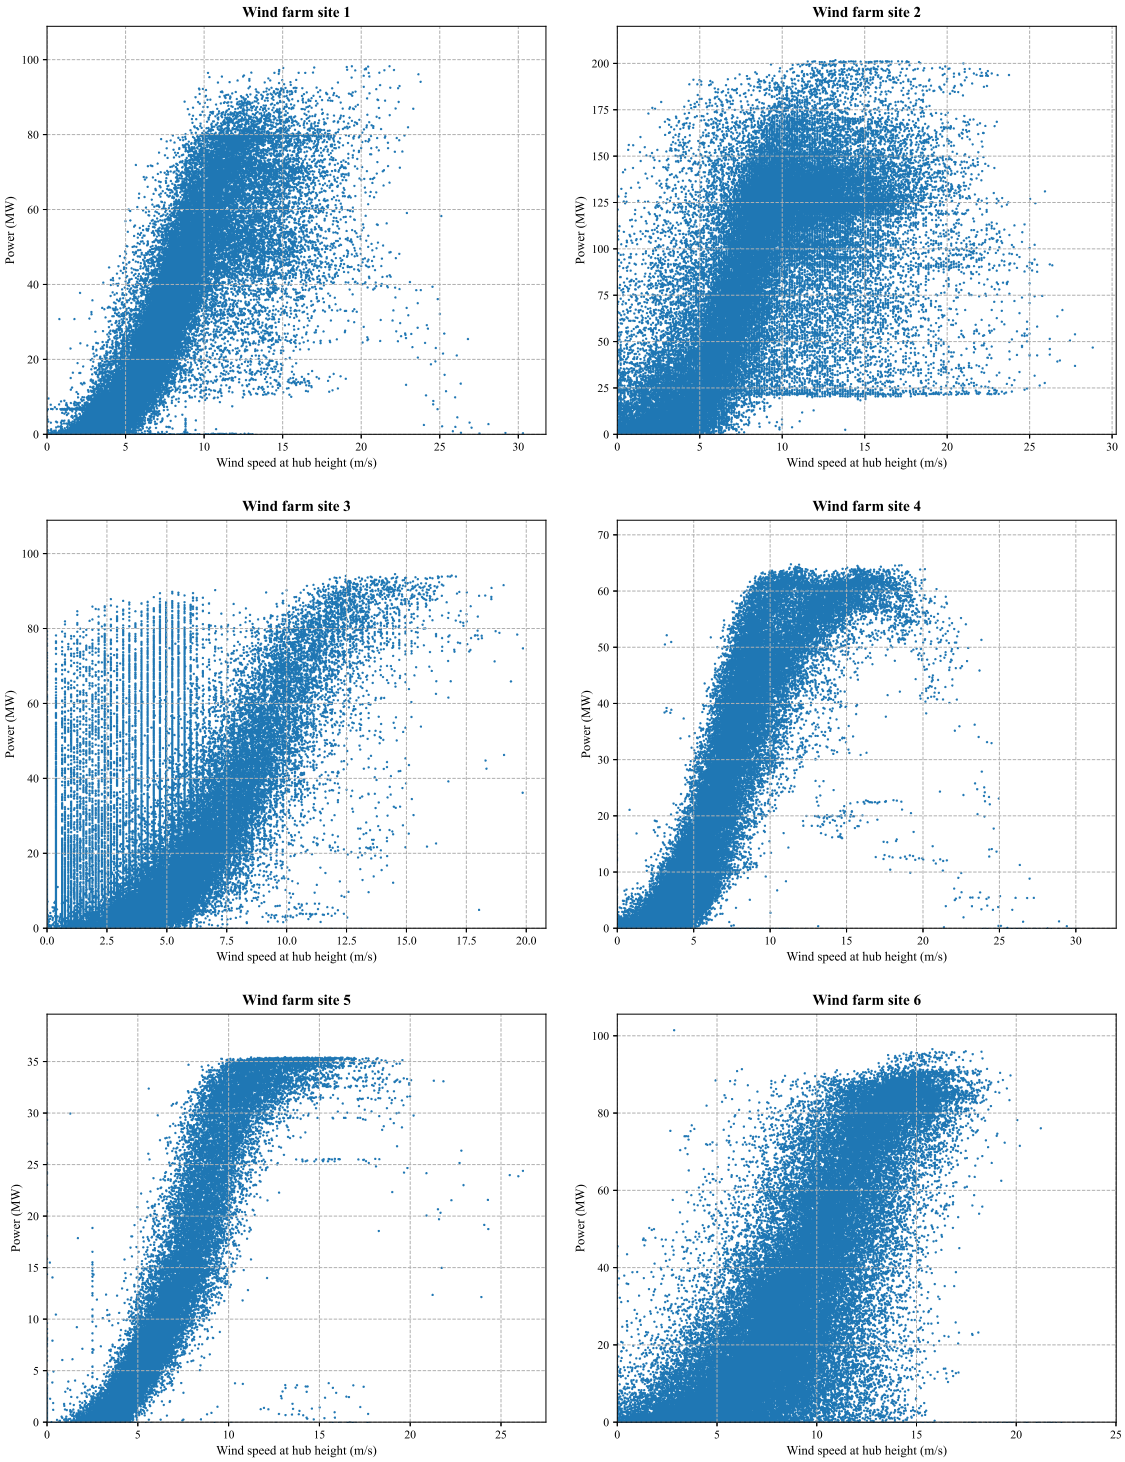

图 2.2 六个风电场轮毂高度风速与输出功率散点图

2.4 特征工程与归一化处理

根据上节分析，本文将所有变量均作为输入变量，并采用 Min-Max 归一化处理。具体公式如下：

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{2.1}$$

由于时间反应的季节也会对风电功率产生影响，因此将时间戳进行正余弦变换。具体公式如下：

$$\begin{cases} hour_sin = \sin\left(2\pi\dfrac{hour}{24}\right) \\ hour_cos = \cos\left(2\pi\dfrac{hour}{24}\right) \\ day_sin = \sin\left(2\pi\dfrac{day}{365}\right) \\ day_cos = \cos\left(2\pi\dfrac{day}{365}\right) \end{cases} \tag{2.2}$$

2.5 滑动时间窗口构造

本文建立的是时间序列预测模型，原长序列没有明确的输入输出，需要将数据构造成为成对的样本 (X,y)。如图2.3所示，将前 n 个时间步的数据作为输入 X，将第 $n+1$ 个时间步的数据作为标签 y。按照指定的步长滑动窗口，可以得到多个样本。

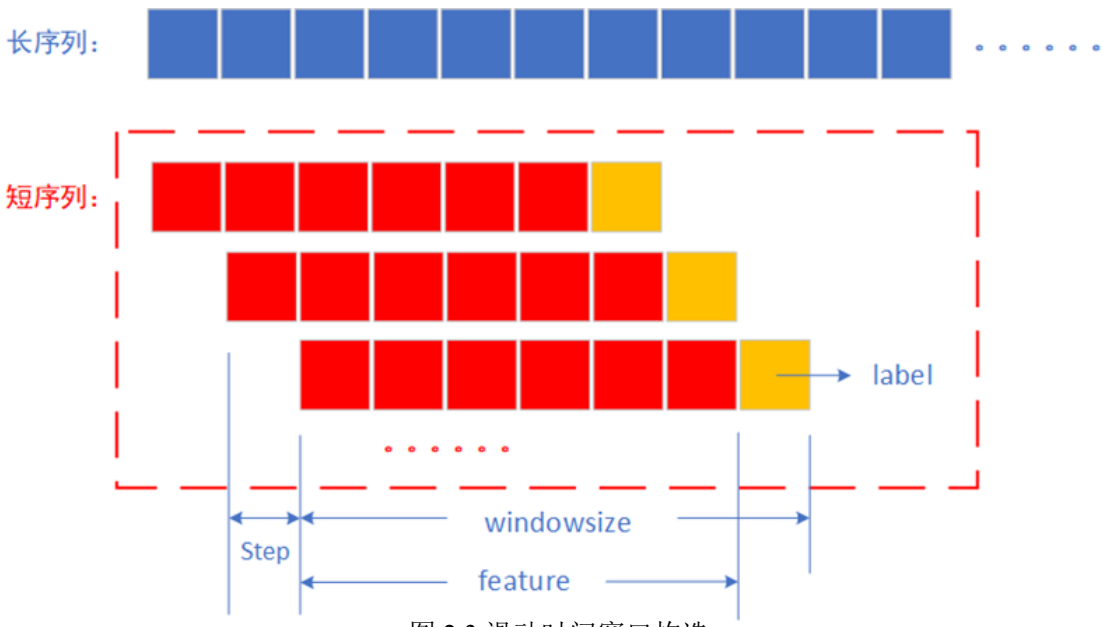

图 2.3 滑动时间窗口构造

2.6 训练集、验证集和测试集划分

3 深度学习预测模型理论基础

3.1 卷积神经网络 CNN 原理

卷积神经网络（Convolutional Neural Network, CNN）最初广泛应用于图像处理领域，其核心思想是通过局部连接、权值共享和多层特征抽取，实现对原始数据中局部特征的自动学习。对于风电功率预测这类时间序列任务，通常采用一维卷积神经网络（1D-CNN）对按时间顺序排列的特征序列进行建模。一维卷积在时间序列建模中的关键作用，在于其能够有效提取局部时序特征。所谓局部时序特征，是指在一个较短时间范围内相邻数据点之间所蕴含的变化规律，例如风速的短时波动、风向的快速偏移、功率的局部爬升与下降趋势等。风电功率本质上受短时气象扰动和设备运行状态共同影响，表现出明显的局部波动性和时间相关性。因此，采用一维卷积在固定时间窗口内提取局部模式，有助于模型捕捉“某几个连续时刻特征变化如何影响下一时刻功率输出”这一重要关系，然后将提取到的特征输入到全连接层进行预测。图 3.1展示了 1D-CNN 的基本结构，其主要包括卷积层、池化层和全连接层。

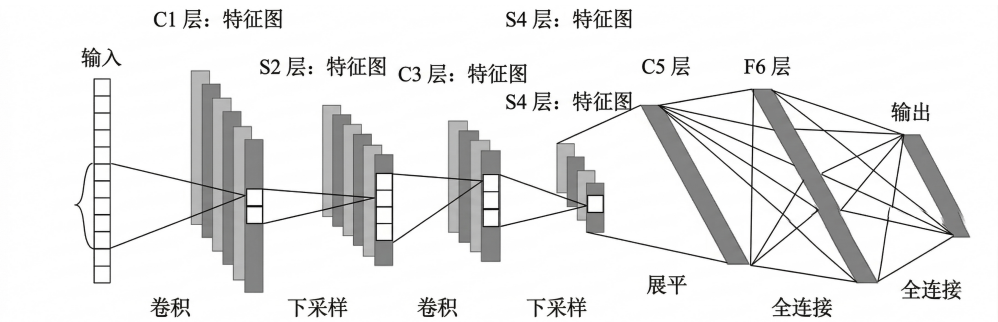

图 3.1 时间序列预测中卷积神经网络基本结构示意图

对于时间序列数据而言，一维卷积的输入通常表示为

$$\mathbf{X} = [x_1, x_2, \dots, x_T],$$

其中，T 表示时间窗口长度，x_t 表示时刻 t 的输入特征。当输入为多变量序列时，也可表示为

$$\mathbf{X} \in \mathbb{R}^{T \times d},$$

其中，d 为每个时刻的特征维数，例如风速、风向、温度、湿度以及历史功率等。CNN 通过卷积核在时间轴上滑动，对连续若干时刻内的数据进行加权求和与非线性变换，从而提取局部相关模式。对于单个卷积核，其输出可表示为

$$y_t = \sigma\left(\sum_{i=0}^{k-1} w_i x_{t+i} + b\right),$$

其中，k 为卷积核长度，w_i 为卷积核参数，b 为偏置项，$\sigma(\cdot)$ 为激活函数。卷积层之后通常接入激活函数和池化层。激活函数如 ReLU 定义为

$$\mathrm{ReLU}(x) = \max(0, x),$$

其作用是引入非线性映射能力，使模型可以逼近更复杂的函数关系。池化层则用于对卷积输出进行降维和特征压缩，减小数据冗余，增强特征鲁棒性。对于一维时间序列，最大池化操作可表示为

$$p_j = \max\{y_{(j-1)s+1}, \cdots, y_{(j-1)s+m}\},$$

其中，m 为池化窗口大小，s 为步长。池化操作保留了局部区域中最显著的响应值，有助于突出关键变化特征，同时减少模型后续计算量。

与传统时间序列分析方法相比，一维卷积具有两个显著优势。其一是局部感受野机制。卷积核每次仅关注输入序列中的一个局部片段，而非直接处理整个长序列，因此更有利于发现短期变化模式。例如，当卷积核长度为 $k = 3$ 时，模型每次只关注相邻 3 个时刻的数据，这种局部观察方式特别适合提取风电功率预测中常见的短期波动特征。其二是权值共享机制。同一个卷积核在整个时间轴上重复使用，意味着模型可以用同一组参数识别不同时间位置上相似的变化模式。这不仅大幅减少了模型参数数量，降低了训练复杂度，也增强了模型对不同时间段相似规律的识别能力。

在风电功率预测任务中，CNN 常作为特征提取器使用。其基本思想是先利用一维卷积从历史时间窗口中自动提取局部变化特征，再将提取得到的高层特征输入至全连接层或循环神经网络中完成预测。特别是在 CNN-LSTM 混合模型中，CNN 负责提取短时局部特征，LSTM 负责建模长期时序依赖，这种结构能够兼顾局部模式识别与长时记忆能力，因此在风电功率预测中表现出较好的效果。

从滑动窗口构造角度来看，假设使用长度为 T 的历史窗口预测未来某一时刻功率，则 CNN 的输入可写为

$$\mathbf{X}^{(n)} = [x_n, x_{n+1}, \cdots, x_{n+T-1}],$$

对应的预测目标为

$$\hat{y}^{(n)} = f(\mathbf{X}^{(n)}),$$

其中，$f(\cdot)$ 表示由卷积层、池化层和输出层组成的非线性映射函数。通过训练，模型能够不断调整卷积核参数，使其更准确地提取与目标功率变化最相关的局部时序特征。

3.2 长短期记忆网络 LSTM 原理

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的循环神经网络（Recurrent Neural Network, RNN），专门用于处理序列数据。与传统 RNN 相比，LSTM 引入了门控机制，能够有效解决 RNN 处理长序列数据时存在的梯度消失或者梯度爆炸问题。其核心是引入了细胞（单元）状态和门控机制。细胞状态类似一个输送带，能直接在整个链上运行，只有少量线性相互作用，信息能够长久保留。LSTM 网络模型如图 3.2

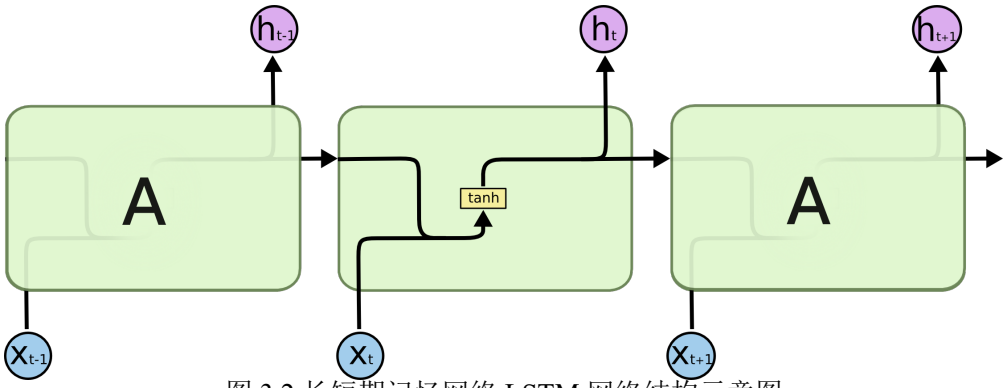

图 3.2 长短期记忆网络 LSTM 网络结构示意图

LSTM 门控机制包含三个部分，即遗忘门、输入门和输出门。图 **??**表示遗忘门，决定从细胞状态中丢弃的信息。遗忘门经过 Sigmoid 激活函数，输出在 0 到 1 之间的值，表示保留的信息比例。遗忘门的公式表示为

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{3.1}$$

其中，$\sigma(\cdot)$ 表示 Sigmoid 激活函数，$\cdot$ 表示向量点积，$[h_{t-1}, x_t]$ 表示将前一时刻的隐藏状态和当前时刻的输入拼接起来，W_f 和 b_f 分别表示遗忘门的权重矩阵和偏置项。接着是输入门，决定从当前输入中保留哪些信息。如图 3.4所示，输入门由两部分组成，一部分是 Sigmoid 激活函数，另一部分是 tanh 激活函数，其公式表示为

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \tag{3.2}$$

其中，$\sigma(\cdot)$ 表示 Sigmoid 激活函数，$\cdot$ 表示向量点积，$[h_{t-1}, x_t]$ 表示将前一时刻的隐藏状态和当前时刻的输入拼接起来，W_i 和 b_i 分别表示输入门的权重矩阵和偏置项，$\tilde{C}_t$ 表示候选细胞状态。

细胞状态的更新过程如图 **??**所示，公式为

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{3.3}$$

其中，C_t 表示当前时刻的细胞状态，C_{t-1} 表示前一时刻的细胞状态，f_t 表示遗忘门，i_t 表示输入门，$\tilde{C}_t$ 表示候选细胞状态，$\odot$ 表示向量点积。

输出门决定从细胞状态中输出哪些信息，如图 **??**所示，其公式表示为

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) h_t = o_t \odot \tanh(C_t) \tag{3.4}$$

其中，$\sigma(\cdot)$ 表示 Sigmoid 激活函数，$\cdot$ 表示向量点积，$[h_{t-1}, x_t]$ 表示将前一时刻的隐藏状态和当前时刻的输入拼接起来，W_o 和 b_o 分别表示输出门的权重矩阵和偏置项，$\odot$ 表示向量点积，$\tanh(\cdot)$ 表示 tanh 激活函数。

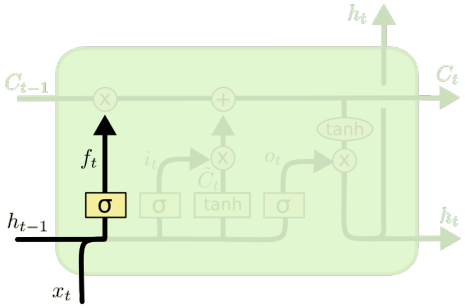

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \ + \ b_f\right)$$

图 3.3 长短期记忆网络 LSTM 遗忘门

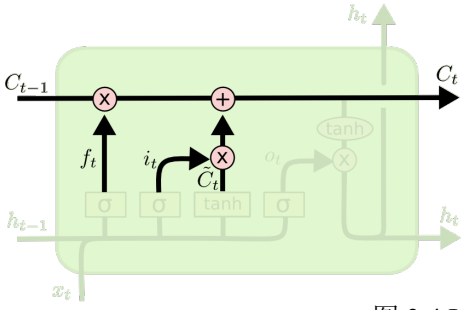

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

图 3.4 LSTM 输入门

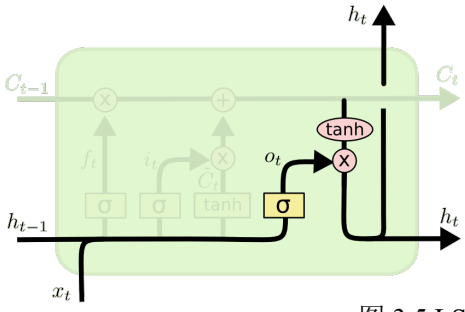

$$o_t = \sigma\left(W_o \ [h_{t-1}, x_t] \ + \ b_o\right)$$
$$h_t = o_t * \tanh\left(C_t\right)$$

图 3.5 LSTM 细胞状态

3.3 门控循环单元 GRU 原理

门循环单元是 LSTM 的简化变体，它同样引入了门控机制，但结构比 LSTM 更简单，参数更少，因此计算效率更高。GRU 通过引入更新门和重置门来控制隐状态，能够有效地捕捉序列中的长期依赖关系。

3.3.1 重置门和更新门

图3.6描述了重置门和更新门的输入，输入是由前一时刻的隐状态和当前时刻的隐状态给出。两个门的输出由 Sigmoid 激活函数给出。对于给定的时间步 t，假设输入是一个小量 $x_t \in \mathbb{R}^{n_{in}}$（样本个数，输入个数），上一个时间步的隐状态是 $H_{t-1} \in \mathbb{R}^{n_{hidden}}$（隐藏单元个数 h）。那么，重置门 R_t 和更新门 Z_t 的计算如下所示：

$$R_t = \sigma(W_r \cdot [H_{t-1}, x_t] + b_r) Z_t = \sigma(W_z \cdot [H_{t-1}, x_t] + b_z) \tag{3.5}$$

其中，$\sigma(\cdot)$ 表示 Sigmoid 激活函数，$\cdot$ 表示向量点积，W_r 和 b_r 分别表示重置门的权重矩阵和偏置项，W_z 和 b_z 分别表示更新门的权重矩阵和偏置项。

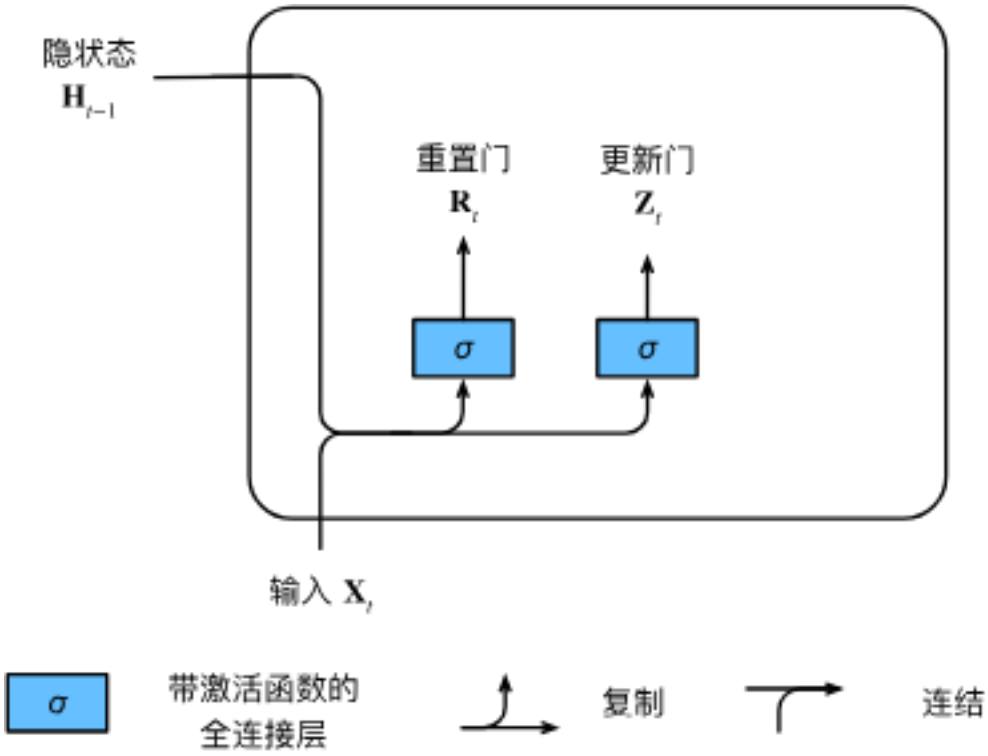

图 3.6 门控循环单元 GRU 重置门和更新门

3.3.2 候选隐状态

在门控循环单元（GRU）结构中，候选隐状态（Candidate Hidden State）的核心作用是整合当前时刻的输入信息与经过选择后的历史信息。为了实现这一目标，我们将重置门 $\mathbf{R}_t$ 与传统的隐状态更新机制相结合。对于时间步 t，给定当前输入 $\mathbf{X}_t \in \mathbb{R}^{n \times d}$ 和上一时刻隐状态 $\mathbf{H}_{t-1} \in \mathbb{R}^{n \times h}$，候选隐状态 $\tilde{\mathbf{H}}_t \in \mathbb{R}^{n \times h}$ 的计算公式如下：

$$\tilde{\mathbf{H}}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xh} + (\mathbf{R}_t \odot \mathbf{H}_{t-1}) \mathbf{W}_{hh} + \mathbf{b}_h)$$

其中，$\mathbf{W}_{xh} \in \mathbb{R}^{d\times h}$ 和 $\mathbf{W}_{hh} \in \mathbb{R}^{h\times h}$ 为可学习的权重参数，$\mathbf{b}_h \in \mathbb{R}^{1\times h}$ 为偏置项。符号 $\odot$ 表示 Hadamard 积（按元素乘法）。在此计算过程中，我们采用 tanh 非线性激活函数，以确保候选隐状态的值域被限制在 $(-1, 1)$ 区间内。该机制设计的精妙之处在于重置门 $\mathbf{R}_t$ 对历史状态的影响力控制：信息保留：当重置门 $\mathbf{R}_t$ 的元素接近 1 时，模型倾向于保留上一时刻的隐状态，此时的计算流程退化为传统的循环神经网络（RNN）更新模式。状态重置：当重置门 $\mathbf{R}_t$ 的元素接近 0 时，上一时刻的隐状态 $\mathbf{H}_{t-1}$ 将被“丢弃”。此时，候选隐状态主要取决于当前输入 $\mathbf{X}_t$，其本质相当于一个以 $\mathbf{X}_t$ 为输入的多层感知机（MLP）输出。通过这种方式，重置门允许模型在处理序列数据时，灵活地选择忽略与当前语义无关的历史信息，从而有效地缓解了梯度消失问题，增强了模型捕获短期依赖关系的能力。

3.3.3 隐状态更新

在得到候选隐状态 $\tilde{\mathbf{H}}_t$ 后，GRU 通过更新门 $\mathbf{Z}_t$ 确定当前时刻最终的隐状态 $\mathbf{H}_t \in \mathbb{R}^{n\times h}$。这一步实际上是对旧状态 $\mathbf{H}_{t-1}$ 和新候选状态 $\tilde{\mathbf{H}}_t$ 之间进行按元素的凸组合（Convex Combination）。

最终的隐状态更新公式为：

$$\mathbf{H}_t = \mathbf{Z}_t \odot \mathbf{H}_{t-1} + (1 - \mathbf{Z}_t) \odot \tilde{\mathbf{H}}_t \tag{3.6}$$

具体的计算流程及数据流向如图 3.7 所示。

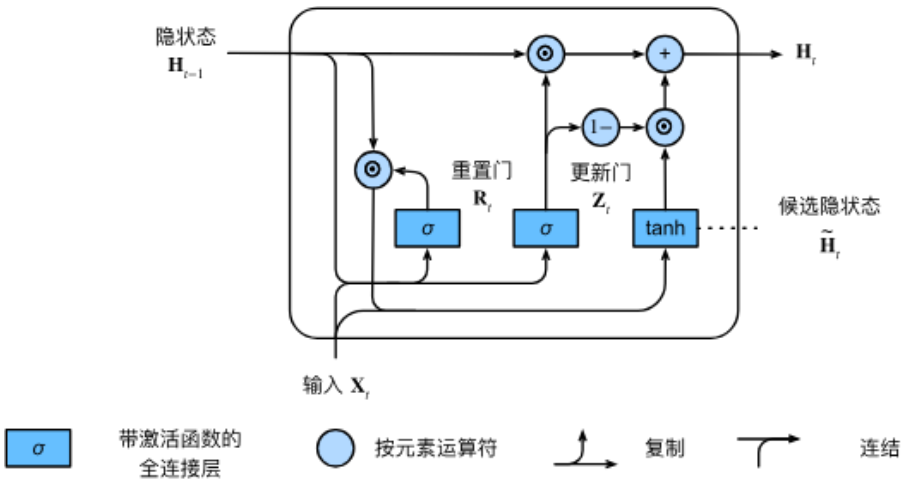

图 3.7 GRU 单元内部结构与隐状态更新流程

更新门 $\mathbf{Z}_t$ 的引入使得模型具备了强大的长程依赖捕获能力：

- **信息传递**：当 $\mathbf{Z}_t$ 趋于 1 时，模型倾向于忽略当前时刻的输入，直接将旧状态 $\mathbf{H}_{t-1}$ 传递至下一时刻，从而有效避免了深层网络中的梯度消失问题。
- **信息融合**：当 $\mathbf{Z}_t$ 趋于 0 时，新的隐状态将融合更多的候选状态信息，实现记忆的实时更新。

这种精巧的设计使得 GRU 能够根据时序数据的特性，自主决定历史信息的留存与更新。

3.4 CNN-LSTM 混合模型原理

写 CNN 负责提取局部时序特征、LSTM 负责捕捉长期依赖。

3.5 模型评价指标

MSE

3.6 实验环境与超参数设置

写编程环境、硬件平台、学习率、batch size、epoch、损失函数、优化器等。

4 单一深度学习模型的风电功率预测建模

4.1 CNN 预测模型构建

写网络结构、输入输出维度、参数设置、优缺点。

4.2 LSTM 预测模型构建

写网络层数、隐藏单元数、预测流程。

4.3 GRU 预测模型构建

写其轻量化优势和实现过程。

4.4 三种单模型训练流程设计

写统一的数据输入方式、训练流程图、停止准则。

4.5 单模型初步实验结果分析

简单给出部分结果，为后续综合对比做铺垫。

5 基于 CNN-LSTM 的混合模型构建与优化

5.1 构建 CNN-LSTM 混合模型的必要性分析

解释为什么单一模型有局限。

5.2 CNN-LSTM 网络结构设计

写输入层、卷积层、池化层、LSTM 层、全连接层。

5.3 模型训练过程与参数优化

写学习率调整、dropout、epoch 设置等。

5.4 CNN-LSTM 模型预测流程

可以配流程图。

5.5 混合模型相较于单模型的理论优势分析

专门为第 6 章结果分析做理论支撑。

6 实验结果分析与模型对比

6.1 实验方案设计

说明在多个风电场上的对比实验方案。

6.2 不同模型在同一风场上的预测结果对比

把 CNN、LSTM、GRU、CNN-LSTM 放在同一个风场比较。

6.3 同一模型在不同风场上的泛化性能分析

分析不同风场数据分布差异对模型的影响。

6.4 预测结果可视化分析

包括真实值-预测值曲线、误差曲线、散点图等。

6.5 基于 MAPE、MAE、RMSE 的综合评价

用表格总结。

6.6 模型优缺点与误差来源分析

写风速突变、极端天气、特征信息不足、模型参数设置等因素。

6.7 最优模型选择与适用场景讨论

最终得出 CNN-LSTM 或其他模型是否最优，并说明原因。

7 结论与展望

7.1 研究工作总结

概括完成了哪些工作。

7.2 主要结论

总结四种模型的对比结果和最优模型。

7.3 不足与展望

写数据规模有限、特征类型有限、未来可加入 Attention、Transformer、多步预测、概率预测等。

参考文献

[1] LIU Z, GUO H, ZHANG Y, et al. A Comprehensive Review of Wind Power Prediction Based on Machine Learning: Models, Applications, and Challenges[J/OL]. Energies, 2025, 18(2): 350[2026-03-13]. https://www.mdpi.com/1996-1073/18/2/350. DOI: 10.3390/en18020350.

[2] 韩自奋, 景乾明, 张彦凯, 等. 风电预测方法与新趋势综述[J/OL]. 电力系统保护与控制, 2019, 47(24): 178-187. https://link.cnki.net/doi/10.19783/j.cnki.pspc.190128.

[3] 黎静华, 桑川川, 甘一夫, 等. 风电功率预测技术研究综述[J/OL]. 现代电力, 2017, 34(3): 1-11. https://link.cnki.net/doi/10.19725/j.cnki.1007-2322.2017.03.001.

[4] YANG Y, LOU H, WU J, et al. A survey on wind power forecasting with machine learning approaches[J/OL]. Neural Computing and Applications, 2024, 36(21): 12753-12773[2026-03-13]. https://link.springer.com/10.1007/s00521-024-09923-4.

[5] 孙荣富, 张涛, 和青, 等. 风电功率预测关键技术及应用综述[J/OL]. 高电压技术, 2021, 47(4): 1129-1143. https://link.cnki.net/doi/10.13336/j.1003-6520.hve.20201780.

[6] 徐曼, 乔颖, 鲁宗相. 短期风电功率预测误差综合评价方法[J/OL]. 电力系统自动化, 2011, 35(12): 20-26. https://kns.cnki.net/kcms2/article/abstract?v=tC3tAMdiXNcJ4k7ciwitE9lQAgZJxPL0ANBTgAsE_Q27c_jP_wFUGlcfowU026smF_fIsCHS1t1FtpjZTxfnSoCbOu87MAYgKyUIsjvro4mO_A5K9TrlERzohQDz_mtSOxyzQQ3ggV0j9iUYdv0T7e3gVgkhh_IbcHFyHVQNspCTSN92Im3cSA==&uniplatform=NZKPT&language=CHS.

[7] LIU H, CHEN C. Data processing strategies in wind energy forecasting models and applications: A comprehensive review[J/OL]. Applied Energy, 2019, 249: 392-408[2026-03-04]. https://linkinghub.elsevier.com/retrieve/pii/S0306261919308517. DOI: 10.1016/j.apenergy.2019.04.188.

[8] WU Z, LUO G, YANG Z, et al. A comprehensive review on deep learning approaches in wind forecasting applications[J/OL]. CAAI Transactions on Intelligence

Technology, 2022, 7(2): 129-143[2026-03-13]. https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/cit2.12076.

[9] DUONG HOANG VU L, PHUNG MAC Q, TRAN NGOC K, et al. Multi-step wind power forecasting over 24 hours using a CNN-LSTM hybrid model[J/OL]. Journal of Measurement, Control, and Automation, 2025, 29(4): 59-66[2026-03-13]. https://mca-journal.org/index.php/mca/article/view/345. DOI: 10.64032/mca.v29i4.345.

[10] 李大中, 李颖宇. 基于深度学习与误差修正的超短期风电功率预测[J/OL]. 太阳能学报, 2021, 42(12): 200-205. https://link.cnki.net/doi/10.19912/j.0254-0096.tynxb.2019-1464.

[11] HE X, MA Y, XIE J, et al. Enhanced Wind Power Forecasting Using Graph Convolutional Networks with Ramp Characterization and Error Correction[J/OL]. Energies, 2025, 18(11): 2763[2026-03-13]. https://www.mdpi.com/1996-1073/18/11/2763. DOI: 10.3390/en18112763.

[12] 朱乔木, 李弘毅, 王子琪, 等. 基于长短期记忆网络的风电场发电功率超短期预测[J/OL]. 电网技术, 2017, 41(12): 3797-3802. https://link.cnki.net/doi/10.13335/j.1000-3673.pst.2017.1657.

[13] ZHANG J, YAN J, INFIELD D, et al. Short-term forecasting and uncertainty analysis of wind turbine power based on long short-term memory network and Gaussian mixture model[J/OL]. Applied Energy, 2019, 241: 229-244[2026-03-04]. https://linkinghub.elsevier.com/retrieve/pii/S0306261919304532. DOI: 10.1016/j.apenergy.2019.03.044.

[14] YUAN X, CHEN C, JIANG M, et al. Prediction interval of wind power using parameter optimized Beta distribution based LSTM model[J/OL]. Applied Soft Computing, 2019, 82: 105550[2026-03-04]. https://linkinghub.elsevier.com/retrieve/pii/S1568494619303308. DOI: 10.1016/j.asoc.2019.105550.

[15] WU X, JIANG S, LAI C S, et al. Short-Term Wind Power Prediction Based on Data Decomposition and Combined Deep Neural Network[J/OL]. Energies, 2022, 15(18): 6734[2026-03-13]. https://www.mdpi.com/1996-1073/15/18/6734. DOI: 10.3390/en15186734.